Análisis Predictivo de Enfermedades Respiratorias Usando Datos de Calidad del Aire y Aprendizaje Automático

David Nickolai Parra Ariza
Facultad de Ingeniería, Universidad Nacional de Colombia, Bogotá, Colombia

Autor de correspondencia: Nickolai Parra (correo electrónico: dparraar@unal.edu.co).

Este trabajo se desarrolló como parte de un proyecto académico y no contó con financiación externa.

RESUMEN En ciudades con niveles altos de contaminación atmosférica como Bogotá, las enfermedades respiratorias constituyen un problema relevante de salud pública. Este artículo presenta un análisis predictivo de la propensión a enfermedades respiratorias a partir de datos históricos de calidad del aire obtenidos de estaciones de monitoreo ambiental. La metodología se fundamenta en la recolección, procesamiento y análisis de condiciones ambientales. Estas variables fueron integradas mediante técnicas de análisis de datos y aprendizaje automático. A partir de estos datos, se desarrollaron modelos predictivos capaces de identificar patrones temporales y espaciales relacionados con la incidencia de enfermedades respiratorias en diferentes zonas de la ciudad. Los resultados incluyen la estructuración de información ambiental por zonas geográficas, la identificación de áreas con mayor propensión al riesgo respiratorio y la generación de visualizaciones espaciales que facilitan la interpretación de los hallazgos. Estos resultados evidencian el potencial del uso de datos de calidad del aire y técnicas de inteligencia artificial como herramientas de apoyo para la toma de decisiones en salud pública.

ABSTRACT In cities with high levels of atmospheric pollution such as Bogotá, respiratory diseases constitute a significant public health concern. This article presents a predictive analysis of respiratory disease propensity based on historical air quality data obtained from environmental monitoring stations. The methodology is based on the collection, processing, and analysis of environmental conditions. These variables were integrated using data analysis techniques and machine learning methods. Based on this information, predictive models were developed to identify temporal and spatial patterns associated with the incidence of respiratory diseases across different areas of the city. The results include the structuring of environmental information by geographic zones, the identification of areas with higher respiratory risk propensity, and the generation of spatial visualizations that facilitate the interpretation of the findings. These results demonstrate the potential of air quality data and artificial intelligence techniques as decision-support tools for public health planning.

PALABRAS CLAVE análisis espacial, aprendizaje automático, calidad del aire, enfermedades respiratorias, salud pública.

INDEX TERMS air quality, machine learning, public health, respiratory diseases, spatial analysis.

I. INTRODUCCIÓN

La contaminación atmosférica representa uno de los desafíos ambientales y de salud pública más críticos de la era contemporánea. El aire contaminado genera enfermedades graves del sistema respiratorio y circulatorio, afectando de manera desproporcionada a poblaciones vulnerables como: niños, adultos mayores y personas con enfermedades crónicas preexistentes. La exposición prolongada a estos contaminantes incrementa significativamente el riesgo de desarrollar asma, enfermedad pulmonar obstructiva crónica (EPOC) y cáncer [1]. En este contexto, el monitoreo y la predicción de la calidad del aire no son simplemente herramientas de gestión ambiental, sino mecanismos esenciales para la protección de la salud colectiva.

Entre los contaminantes de mayor relevancia clínica y epidemiológica se encuentran el material particulado ($PM_{2.5}$ y PM_{10}), el dióxido de azufre (SO_2), el monóxido de carbono (CO), los óxidos de nitrógeno (NO y NO_2) y el ozono troposférico (O_3). Debido a su pequeño diámetro, las partículas finas pueden penetrar profundamente en el sistema respiratorio y circulatorio, ocasionando problemas graves de salud [1][2].

El pronóstico de la calidad del aire ha evolucionado considerablemente en las últimas décadas, transitando desde enfoques estadísticos clásicos hasta técnicas avanzadas de inteligencia artificial. Bernacki y Scherer [1] presentan una revisión sistemática de los métodos basados en datos para la predicción de concentraciones de contaminantes, analizando desde modelos estadísticos hasta modelos híbridos. Según este estudio, los modelos basados en aprendizaje profundo emergen como los enfoques más prometedores para la predicción precisa de la calidad del aire.

En particular, el material particulado fino ($PM_{2.5}$) y grueso (PM_{10}) constituye uno de los indicadores más utilizados para evaluar la calidad del aire urbano debido a su estrecha relación con efectos adversos en la salud pública. En primer lugar, Bekkar et al. [2] (en un estudio aplicado en China) destacan que la predicción de concentraciones de material particulado en entornos de ciudades inteligentes es fundamental para anticipar episodios críticos de contaminación y reducir su impacto sanitario mediante sistemas de alerta temprana basados en aprendizaje profundo. Por su parte, Karim et al. [3] (en el contexto de India) subrayan que el PM_{10}, debido a su capacidad de penetrar en el sistema respiratorio, se asocia con: deterioro de la función pulmonar, exacerbación del asma y aumento del riesgo de enfermedades cardiovasculares. Estos contaminantes son medidos tradicionalmente a través de redes de estaciones de monitoreo terrestre que registran concentraciones horarias y diarias, aunque recientemente se han complementado con datos de sensores remotos y variables atmosféricas derivadas de satélite para mejorar la cobertura espacial y la capacidad predictiva.

Así mismo, los análisis epidemiológicos sobre los efectos en salud de la contaminación atmosférica han tendido históricamente a centrarse en contaminantes individuales, dejando de lado la realidad de que las poblaciones están expuestas simultáneamente a mezclas complejas de múltiples contaminantes. Mwase et al. [4] abordan esta limitación aplicando métodos de clustering no supervisado e investigando los efectos conjuntos de variables ambientales sobre hospitalizaciones por enfermedades respiratorias (ER) y cardiovasculares (ECV) en Sudáfrica. Sus resultados mostraron que la exposición a mezclas con concentraciones elevadas de SO_2, NO_2, $PM_{2.5}$ y PM_{10} combinadas con niveles bajos de O_3 incrementan significativamente el riesgo de hospitalización por ER. Este estudio subraya el potencial del aprendizaje automático no supervisado como herramienta para evaluar los efectos conjuntos de mezclas contaminantes.

Además, la creciente disponibilidad de datos provenientes de redes de monitoreo ambiental en ciudades inteligentes ha abierto nuevas posibilidades para desarrollar modelos predictivos que vinculen la calidad del aire con sus efectos sobre la salud. Morales-García et al. [5] destacan que los modelos de predicción basados en aprendizaje automático permiten anticipar la evolución de la contaminación urbana a partir de datos recolectados por redes de sensores IoT (Internet of Things). El estudio, realizado en múltiples ciudades españolas, demostró que los sistemas de predicción de calidad del aire constituyen instrumentos de apoyo para la toma de decisiones por parte de planificadores urbanos y autoridades sanitarias.

En este contexto, aunque la literatura internacional evidencia avances significativos, persisten desafíos asociados a la integración simultánea de variables atmosféricas dentro de un mismo marco predictivo. Por ello, el presente trabajo propone un enfoque integral basado en técnicas de aprendizaje automático para analizar y predecir concentraciones de contaminantes atmosféricos, incorporando información proveniente de estaciones de monitoreo.

REFERENCIAS

[1] J. Bernacki and R. Scherer, "A comprehensive review of data-driven techniques for air pollution concentration forecasting," *Sensors*, vol. 25, no. 19, p. 6044, 2025, doi: 10.3390/s25196044.

[2] A. Bekkar, B. Hssina, S. Douzi, and K. Douzi, "Air-pollution prediction in smart city, deep learning approach," *Journal of Big Data*, vol. 8, p. 161, Dec. 2021, doi: 10.1186/s40537-021-00548-1.

[3] M. Karim, S. Tomar, S. K. Shah, and T. P. Singh, "Analyzing and predicting PM_{10} using remote sensing and machine learning: A case study of Delhi, India," *Discover Applied Sciences*, vol. 7, p. 1291, Oct. 2025, doi: 10.1007/s42452-025-07818-0.

[4] N. S. Mwase, M. Kebalepile, W. Junger, and J. Wichmann, "Unsupervised machine learning to investigate the joint effects of SO_2, NO_2, O_3, $PM_{2.5}$ and PM_{10} on respiratory and cardiovascular hospital admissions in the Vaal Triangle Airshed Priority Area, South Africa," *Atmospheric Environment*, vol. 366, p. 121660, 2026, doi: 10.1016/j.atmosenv.2025.121660.

[5] J. Morales-García, E. Ramos-Sorroche, S. Balderas-Díaz, G. Guerrero-Contreras, A. Muñoz, J. Santa, and F. Terroso-Sáenz, "Reducing pollution health impact with air quality prediction assisted by mobility data," *IEEE Journal of Biomedical and Health*

Informatics, vol. 29, no. 12, pp. 9210–9220, Dec. 2025, doi: 10.1109/JBHI.2024.3508466.